

Clustering e Bayesian Regression: un'indagine Bayesiana sulle Dinamiche di Spotify

Nel panorama odierno dello streaming musicale, Spotify rappresenta una delle piattaforme leader a livello globale. Ogni brano sulla piattaforma non è solo un'opera artistica, ma è tradotto in una serie di feature quantitative che ne descrivono l'impronta sonora.

Questo studio si propone di esplorare la struttura di questi dati musicali, con lo scopo di comprendere meglio le dinamiche che accomunano i diversi brani e ne influenzano il successo.

In primo luogo, l'obiettivo principale dello studio è l'identificazione di pattern strutturali: i brani verranno raggruppati in cluster sulla base delle loro affinità acustiche, isolando canzoni che presentano comportamenti musicali simili.

In secondo luogo, si è voluto comprendere in che misura questi attributi strutturali abbiano un effetto sulla metrica di popolarità della canzone all'interno della piattaforma.

Attraverso l'impiego di modelli bayesiani, si intende decodificare le relazioni che legano tra loro le diverse canzoni di Spotify, cercando di rispondere a un quesito cruciale del mercato discografico: fino a che punto la "matematica" intrinseca di un brano è in grado di influenzarne e prevederne il successo?

1. DATASET

Il set di dati iniziale "*Spotify*" è composto da 32.883 osservazioni (rappresentanti singoli brani musicali) e 17 variabili:

Variabili quantitative: Feature audio, costituiscono gli input per i modelli di Clustering e Regression. Si tratta di misurazioni oggettive della traccia, che includono proprietà acustiche (*acousticness*, *instrumentalness*, *speechiness*, *liveness*), parametri di atmosfera ed energia (*danceability*, *energy*, *valence*) e caratteristiche tecniche (*tempo*, *loudness*, *duration_ms*, *key*, *mode*).

Variabili qualitative: Includono identificativi (titolo, artista) e genere musicale. Queste ultime non verranno utilizzate all'interno dei modelli. Serviranno esclusivamente come etichette per validare a posteriori i risultati, per verificare se i cluster ottenuti corrispondono a reali suddivisioni per genere musicale.

Variabile Target: *track_popularity*, una metrica quantitativa che misura il successo del brano e che fungerà da variabile dipendente nella fase di regressione.

2. PRE PROCESSING

Il preprocessing del dataset "*Spotify*" si è articolato in tre fasi chiave. Inizialmente, le variabili con forte asimmetria hanno subito una trasformazione logaritmica, seguita dalla standardizzazione di tutte le feature quantitative.

L'analisi di correlazione ha rivelato un'evidenza cruciale: nessuna variabile presenta una correlazione lineare diretta con *track_popularity*. Infine, per far fronte all'elevato costo computazionale delle simulazioni MCMC, il dataset è stato ridotto estraendo un sub-sample del 5%. Per non alterare la struttura originaria, si è applicato un campionamento stratificato sulla variabile *playlist_genre*, mantenendo intatte le proporzioni dei macro-generi musicali.

3. VARIABLE SELECTION

Per individuare quali feature audio fossero realmente rilevanti per spiegare la popolarità di un brano, si è optato per l'approccio **Spike and Slab**.

Il campionamento ha previsto 3 catene parallele da 12.000 iterazioni ciascuna (di cui 2.000 di warmup).

L'analisi diagnostica ha validato la robustezza dell'inferenza: i traceplot evidenziano un mixing ottimale delle catene e l'assenza di trend anomali, garantendo l'avvenuta convergenza del modello. Parallelamente, la valutazione degli Intervalli di Credibilità (HDI al 95%) ha permesso di valutare la significatività statistica di variabili chiave come *loudness* ed *energy*;

Per determinare il set finale di variabili, è stata calcolata la **Posterior Inclusion Probability (PIP)** per ciascuna feature, valutando i risultati attraverso tre criteri decisionali: Median Probability Model (MPM), Highest Posterior Density (HPD), Hard Shrinkage (HS). I criteri HPD e MPM convergono in modo netto sull'importanza di quattro predittori principali, che superano abbondantemente la soglia di inclusione. Il dataset ottimizzato per le fasi successive è stato quindi ridotto alle sole variabili rilevanti: *loudness*, *energy*, *duration_ms* e *instrumentalness*.

4. K-MEANS

Per stabilire un punto di riferimento (baseline) e indagare la struttura spaziale delle quattro variabili selezionate precedentemente, è stato implementato l'algoritmo **K-Means**.

Per individuare il numero ottimale di partizioni latenti, si è fatto ricorso all'**Elbow Method**, calcolando l'Inertia per valori di *K* compresi tra 2 e 10. L'andamento della curva ha mostrato una flessione in corrispondenza di *K*=3, suggerendo l'adozione di questo valore come numero ideale di gruppi. L'algoritmo ha conseguentemente prodotto tre cluster, composti rispettivamente da 154, 864 e 613 osservazioni.

Valutando la qualità di questa partizione, la metrica **Average Silhouette Width** ha restituito un punteggio di 0.30. Questo valore denota una struttura di classificazione moderata: i gruppi individuati sono fondati su basi reali e non casuali, ma presentano inevitabili zone di sovrapposizione lungo i confini. Questo limite è del tutto atteso quando si trattano dati musicali, ambito in cui i vari generi tendono a sfumare l'uno nell'altro.

Nella visualizzazione grafica, si è applicata l'**Analisi delle Componenti Principali (PCA)** per proiettare i dati in uno spazio tridimensionale. Questa operazione ha garantito un'ottima rappresentatività strutturale, con le prime tre componenti capaci di spiegare cumulativamente il 93% della varianza totale (rispettivamente il 42% per la PC1, il 26% per la PC2 e il 24% per la PC3). Analizzando la matrice delle rotazioni, è stato possibile assegnare un significato ai nuovi assi cartesiani: la prima componente (PC1) agisce come asse dell'intensità, essendo dominata da *loudness* ed *energy*; la seconda (PC2) cattura la struttura del brano, influenzata negativamente da *instrumentalness* per distinguere i brani cantati da quelli strumentali; la terza (PC3), infine, è dominata dalla durata del brano. Sfruttando questa trasformazione, lo scatterplot tridimensionale ha consentito di osservare come le tre partizioni individuate dal K-Means si dispongano e si separino lungo le nuove direttrici di intensità, tipologia e tempo.

5. BAYESIAN CLUSTERING

Per gestire l'incertezza dei confini dei generi musicali, è stato implementato un modello probabilistico **Gaussian Mixture Model (GMM)**, applicato alle quattro variabili più rilevanti (*loudness, energy, duration_ms, instrumentalness*).

Ogni brano è modellato come proveniente da una mistura di $K=3$ distribuzioni normali multivariate, con ipotesi di indipendenza delle singole variabili.

Le distribuzioni a priori scelte includono una *Dirichlet* debolmente informativa per i pesi della mistura (w) e una struttura *Normal-Inverse-Gamma* per medie e varianze.

Inoltre, il modello adotta uno schema di **Data Augmentation** introducendo un vettore di variabili di allocazione $s_i \in \{1, \dots, K\}$. Tale componente, campionata da una distribuzione prior Categorical, permette di trattare le etichette dei cluster come parametri stimabili, rendendo il campionatore di Gibbs trattabile computazionalmente.

Il modello ha campionato 3 catene parallele per 2.000 iterazioni (1.000 di warmup). L'analisi diagnostica MCMC ha confermato l'ottima convergenza del modello: la statistica $\hat{R}$ è risultata perfettamente pari a 1.00 per tutti i parametri monitorati (pesi w e medie μ).

L'efficienza del campionamento è confermata dai valori del numero di campioni effettivi (n_{eff}), che per tutti i parametri (medie e pesi) sono risultati ampiamente soddisfacenti, mantenendosi sopra le 1500 unità.

Le stime a posteriori dei pesi della mistura (w) rivelano la seguente distribuzione dei gruppi:

$w[1]$: Media a posteriori 0.10 (Cluster 1)

$w[2]$: Media a posteriori 0.17 (Cluster 2)

$w[3]$: Media a posteriori 0.74 (Cluster 3)

Per estrarre la partizione "ottimale" dalle iterazioni simulate, si è costruita la **Posterior Similarity Matrix** e si è minimizzata la **Binder Loss**. L'impiego della matrice di similarità a posteriori permette di aggirare il problema del **label switching**.

La stima puntuale risultante ha prodotto la seguente ripartizione:

146 brani assegnati al Cluster 1 (9%)

267 brani assegnati al Cluster 2 (16.4%)

1218 brani assegnati al Cluster 3 (74.7%)

6. CONFRONTO BAYESIAN CLUSTERING E K-MEANS

Per valutare l'impatto dell'approccio probabilistico, le assegnazioni del modello Bayesiano (GMM) sono state confrontate con il K-Means tramite una matrice di transizione. I risultati evidenziano una macro-coerenza strutturale tra i due metodi, accompagnata però da una differenza nella gestione delle aree di confine. Da un lato, si osserva una mappatura quasi perfetta per i gruppi più definiti: l'intera totalità (100%) delle osservazioni del Cluster 1 del K-Means è confluita nel Cluster 2 Bayesiano, così come il Cluster 2 è stato assorbito per il 90.4% dal macro-Cluster 3 probabilistico. Dall'altro lato, la divergenza metodologica emerge nell'analisi del Cluster 3 del K-Means, situato verosimilmente in una zona a densità mista. In quest'area, il modello Bayesiano ha frammentato il gruppo originario: il 71.3% dei brani è rimasto nel Cluster 3, mentre un significativo 23.7% è stato riallocato nel Cluster 1 Bayesiano.

Questo scostamento dimostra l'efficacia del GMM nelle zone di transizione musicale: laddove il

K-Means imponeva rigidi confini geometrici basati sulla sola distanza dai centroidi, l'approccio Bayesiano ha ridistribuito le osservazioni pesando le probabilità a posteriori, assorbendo le sovrapposizioni intrinseche tra generi in modo più naturale e aderente alla realtà dei dati.

7. ANALISI DEI CLUSTER E VALIDAZIONE QUALITATIVA

Per comprendere il reale significato della classificazione operata dal modello Bayesiano, si è proceduto a una validazione incrociata. Le etichette dei cluster sono state incrociate con quelle dei dati originali dei brani (*playlist_genre*, *track_name*, *track_artist*), al fine di osservare la composizione percentuale dei gruppi e isolare tracce rappresentative. L'analisi ha permesso di delineare tre profili musicali distinti:

- **Cluster 1: "Soft / Acoustic"**: seppur numericamente minoritario, presenta un'impronta sonora molto definita, caratterizzata da bassi livelli di energia e loudness. È dominato da brani R&B (33.6%) e Rock (24.7%), seguiti dal Rap (18.5%). Tracce come *Passionfruit* (Drake), *please, please, please* (The Smiths), confermano la natura soft, acustica o malinconica di questo raggruppamento.
- **Cluster 2: "Instrumental / EDM"**: cattura i brani con strutture atipiche, in cui la componente vocale è ridotta a favore di produzioni elettroniche, beat intensi o ampie sezioni strumentali, infatti quasi la metà del cluster è costituita da musica EDM (45.7). All'interno del cluster vi sono tracce dal sound particolare come *Animals* (Martin Garrix), *bad guy* (Billie Eilish) e hit indie-elettroniche come *Time to Pretend* (MGMT).
- **Cluster 3: "Mainstream / Radio"**: rappresenta il "cuore" del mercato musicale di Spotify. Al suo interno, le differenze tra i generi si assottigliano, infatti la distribuzione dei generi è estremamente omogenea ed equilibrata. Nessun genere prevale in modo netto: Latin (19.2%), Rap (18.1%), Pop (17.2%), R&B (16.8%), EDM e Rock (entrambi al 14.4%). Questo gruppo racchiude le canzoni costruite per piacere al grande pubblico, accomunate da strutture standard, alti livelli di energia e durate radio-friendly. Nel cluster sono infatti presenti Hit globali ad alta rotazione radiofonica come *I don't care* (Ed Sheeran), *Blinding Lights* (The Weeknd) o grandi classici come *Dancing Queen* (ABBA).

8. REGRESSIONE BAYESIANA

Dopo aver mappato la struttura del dataset, si è voluto definire se le feature audio abbiano un impatto quantificabile sulla popolarità di un brano. Per evitare la forzatura di imporre un'unica relazione lineare sui vari profili musicali, si è scelto di implementare tre distinti modelli di regressione bayesiana, uno per ciascun cluster.

Per ogni modello è stata definita una verosimiglianza Normale, una distribuzione a priori Normale Multivariata per i coefficienti (β) e un'Inv-Gamma per la varianza.

Il campionamento MCMC, impostato su 3 catene da 2.000 iterazioni con 500 di warmup, ha restituito traceplot che certificano la convergenza delle catene nei 3 vari cluster.

L'analisi degli intervalli di credibilità (HDI al 95%) ha portato alla luce dinamiche predittive eterogenee, fortemente dipendenti dal contesto musicale. Nel Cluster "*Soft/Acoustic*", l'elevata incertezza a posteriori (con parametri che includono frequentemente lo zero) suggerisce che le micro-variazioni acustiche non rappresentano predittori stabili della popolarità del brano. Nel gruppo "*Instrumental/EDM*" emergono invece effetti più definiti: il coefficiente legato all'energy, mostrando un intervallo interamente negativo, indica che picchi di intensità estrema tendono a

penalizzare la traccia rispetto a produzioni più bilanciate. Nel macro-Cluster "*Mainstream / Radio*", si osserva un impatto positivo della loudness contrapposto a un marcato effetto negativo dell'instrumentalness; a conferma che, nel mercato generalista, l'assenza di una linea vocale costituisce un fattore penalizzante per gli ascolti.

Per valutare la bontà di adattamento delle stime, è stato valutato l'indice R^2 :

- Cluster 1: $R^2 = 1.8\%$
- Cluster 2: $R^2 = 8.0\%$
- Cluster 3: $R^2 = 5.4\%$

Nonostante la convergenza e la capacità di isolare queste tendenze locali, la validazione dei modelli suggerisce che l'impronta del suono riesce a spiegare meno del 10% della varianza totale della popolarità.

Questa evidenza statistica certifica un importante aspetto dell'industria discografica: le features audio operano come una condizione necessaria ma non sufficiente per il successo di una traccia, mentre la popolarità risulta governata da ulteriori variabili latenti esterne all'audio. Sono le strategie di marketing, la notorietà pregressa dell'artista, il posizionamento e le improvvise ondate virali sui social media a dettare le reali regole del successo sulla piattaforma.

Se si analizza il Cluster 1 ("*Soft/Acoustic*"), il valore dell'R-quadro risulta molto basso. Tale fenomeno è perfettamente coerente con la natura del gruppo: trattandosi di brani intimi, di nicchia e strutturalmente lontani dalle logiche commerciali e radiofoniche, il loro posizionamento sfugge a qualsiasi modellizzazione acustica. Il successo di una traccia non mainstream segue percorsi atipici, rendendolo di fatto impossibile da prevedere analizzando esclusivamente le componenti quantitative della traccia.

9. MIXTURE OF REGRESSION

In questa fase dell'analisi, si è deciso di testare un approccio alternativo esplorando un modello unificato di **Mixture of Regressions**. Questo modello tenta di individuare partizioni basandosi su come tali caratteristiche influenzano la variabile dipendente, ricercando gruppi di brani definiti dall'equazione di regressione con l'obiettivo di individuare le regole di mercato riguardanti la popolarità di una traccia nei cluster.

Le distribuzioni a priori scelte includono una *Dirichlet* per i pesi della mistura (w), una struttura *Normal-Inverse-Gamma* per i coefficienti beta e varianze. Anche qui il modello adotta uno schema di **Data Augmentation** introducendo un vettore di variabili di allocazione $s_i \in \{1, \dots, K\}$.

L'algoritmo è stato inizializzato richiedendo l'individuazione di $K=3$ cluster per 2.500 iterazioni (500 di burn-in). Tuttavia, la stima puntuale ottenuta mediante minimizzazione del **Binder Loss** sulle partizioni a posteriori ha restituito solamente due cluster. In particolare, sono state individuate:

159 osservazioni nel Cluster 1, 1472 osservazioni nel Cluster 2, 0 osservazioni nel Cluster 3.

Questo risultato si ricollega a quanto scoperto nell'analisi precedente dove il Cluster "*Soft/Acoustic*" presenta un R^2 pari ad appena l'1%. Questo comportamento suggerisce, in modo implicito, che la struttura sonora dei brani musicali segue dinamiche diverse rispetto a quelle che ne determinano il successo sulla piattaforma.

10. RISULTATI CONCLUSIVI

Il presente studio si era posto l'obiettivo di esplorare la struttura del catalogo musicale di Spotify, verificando la possibilità di raggruppare i brani in base alle loro caratteristiche sonore (feature oggettive) per poi testarne l'eventuale capacità predittiva sulla popolarità.

Il clustering è risultato essere lo strumento ottimale per mappare lo spazio sonoro dei brani. Partendo da una baseline (K-Means), l'implementazione del Gaussian Mixture Model (GMM) Bayesiano ha dimostrato solidità strutturale. Il modello probabilistico ha confermato l'esistenza di tre gruppi, sovrapponendosi in gran parte alla classificazione del K-Means. L'analisi qualitativa a posteriori ha rivelato che questi gruppi non sono semplici numeri, ma corrispondono a cluster reali e coerenti: un polo Soft/Acoustic (dominato da R&B e ritmi lenti), un polo Instrumental/EDM (ad alta componente strumentale) ed un vasto macro-gruppo Mainstream (il cuore radiofonico della piattaforma).

L'analisi della capacità predittiva delle feature audio ha prodotto un'evidenza apparentemente controintuitiva, ma dal profondo valore analitico. Sia l'approccio condizionato (le regressioni separate) sia il modello unificato (Mixture of Regressions) convergono verso la medesima conclusione: non esiste un'equazione lineare universale in grado di spiegare il successo di un brano basandosi esclusivamente sulla sua componente acustica.

La popolarità su Spotify emerge come un fenomeno dominato prevalentemente da variabili esterne al segnale audio, quali il posizionamento di marketing, la notorietà dell'artista e le dinamiche di viralità digitale. Tuttavia, nel Cluster "*mainstream*", il modello ha isolato una chiara regola: in questo segmento, l'instrumentalness penalizza sistematicamente la traccia, mentre una loudness elevata agisce come driver positivo. Ciò suggerisce che, pur non garantendo il successo, il mercato imponga precisi requisiti sonori per poter competere nelle fasce più alte delle classifiche.

In conclusione, l'analisi bayesiana ha dimostrato la sua efficacia nel destrutturare e comprendere i dati di Spotify, rivelando che se da un lato è possibile classificare "come suona" un brano, dall'altro il successo commerciale rimane una complessa equazione in cui il marketing e i fattori sociali superano ampiamente le misurazioni acustiche.